

Dossier - Modèles de prédiction des AVC

Chloé Martin

2025-06-09

Abstract

Ce document vise à prédire le risque d'accident vasculaire cérébral (AVC) chez des patients à partir d'un ensemble de données intégrant des variables liées à leur état de santé et à leur mode de vie. L'approche adoptée repose sur la mise en œuvre de plusieurs modèles de classification supervisée, tels que les analyses discriminantes, les forêts aléatoires et les modèles de boosting. L'objectif est d'identifier le modèle le plus robuste et le plus précis afin d'optimiser la détection des patients à risque.

Table of contents

1	Introduction	2
2	Statistiques descriptives	2
2.1	Observation des données manquantes	3
2.2	Analyse de notre variable cible 'stroke'	3
2.3	Analyse des variables numériques	4
2.4	Analyse des variables catégorielles	4
3	Méthodologie	5
3.1	Échantillonnage	5
3.2	Prétraitement des données	5
3.3	Gestion du déséquilibre	6
3.4	Évaluation des modèles : Métriques utilisées	6
4	Les modèles	6
4.1	L'analyse discriminante linéaire (LDA)	6
4.2	L'analyse discriminante quadratique (QDA)	7
4.3	Modèle des k plus proches voisins (knn)	8
4.4	SVM Linéaire (Support Vector Machine)	10
4.5	SVM noyau radial	11
4.6	Arbres de décision CART	13
4.7	Random forest	15
4.8	Boosting	16
5	Comparaison des modèles	18
5.1	Analyse des performances	18
5.2	Conclusion	19
6	Annexe	20
6.1	Annexe A - Introduction	20
6.2	Annexe B - Les modèles	21

1 Introduction

Les accidents vasculaires cérébraux (AVC) constituent un enjeu majeur de santé publique. Selon l'Organisation Mondiale de la Santé (OMS), l'AVC est la **deuxième cause de mortalité dans le monde**, étant responsables d'environ **11 % des décès globaux**. Dans ce contexte, la capacité à identifier les individus à risque, à l'aide de données cliniques et sociodémographiques, apparaît comme un levier essentiel en matière de **prévention médicale**. Ce projet a pour objectif de développer un modèle prédictif de la survenue d'un AVC à partir d'un jeu de données médicales issues de Kaggle, proposé par l'utilisateur *fedesoriano*.

Le jeu de données comprend des informations sur 5110 patients, chacun décrit par 11 variables. La variable cible est nommée **stroke** et indique si le patient a subi un AVC (1) ou non (0).

Afin de mieux comprendre les données utilisées dans ce projet, nous allons présenter un aperçu de la base de données :

Table 1: Aperçu des premières lignes du jeu de données sur les AVC

gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
Male	67	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
Female	61	0	0	Yes	Self-employed	Rural	202.21	NA	never smoked	1
Male	80	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
Female	49	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
Female	79	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

Parmi les variables explicatives, trois sont numériques :

- l'âge,
- l'indice de masse corporelle (IMC),
- le niveau moyen de glucose sanguin.

Les sept autres variables sont catégorielles : le **genre**, la **présence d'hypertension**, les **antécédents de maladie cardiaque**, le **statut marital**, le **type d'activité professionnelle** (enfants, employé, travailleur du secteur privé, indépendant ou n'a jamais travaillé), le **type de résidence** (urbaine ou rurale) et le **statut tabagique** (fumeur, ancien fumeur, non-fumeur ou inconnu).

Ces données permettent de dresser un **profil global des patients**, en intégrant des dimensions médicales, comportementales et sociales, dans le but de **prédire le risque d'AVC**.

2 Statistiques descriptives

Avant de commencer notre étude, il est essentiel de bien comprendre la structure de notre base de données. Cela nous permet de mieux interpréter les résultats et de préparer nos données pour l'analyse. Ainsi, une première étape consiste à réaliser une analyse exploratoire des données, en mettant l'accent sur les statistiques descriptives, les variables clés, et en identifiant les éventuelles valeurs manquantes ou aberrantes. Cette phase nous permet de garantir la qualité de notre modèle prédictif.

2.1 Observation des données manquantes

Une première étape indispensable est la détection des valeurs manquantes, qui peuvent compromettre la qualité des modèles.

La *Figure A.1 en annexe* présente une visualisation de la structure des données manquantes dans notre jeu de données.

La variable ‘bmi’ présente 4 % de données manquantes. Cette proportion étant relativement modérée, nous avons choisi de les imputer plutôt que de supprimer les observations correspondantes.

L’imputation a été réalisée à l’aide de la méthode des k plus proches voisins (k-NN), intégrée aux recettes de prétraitement du package tidymodels.

Table 2: Résumé de la variable ‘bmi’ avant et après imputation

Statistique	Avant Imputation	k=5	k=10
Min.	10.30	10.30	10.30
1st Qu.	23.50	23.70	23.70
Median	28.10	28.15	28.20
Mean	28.89	28.95	28.93
3rd Qu.	33.10	33.10	33.10
Max.	97.60	97.60	97.60
NA’s	201.00	NA	NA

Après comparaison des statistiques descriptives avant et après imputation (avec $k = 5$ et $k = 10$), $k = 5$ a été retenu comme compromis optimal entre stabilité et précision.

La *Figure A.2 en annexe* compare la distribution de la variable bmi avant et après imputation. On observe que les distributions restent très proches, indiquant une **imputation cohérente et non biaisée**.

2.2 Analyse de notre variable cible ‘stroke’

La variable ‘stroke’ est binaire et fortement déséquilibrée.




Figure 1: Distribution de la variable cible

En examinant la répartition de la variable ‘stroke’, on observe 95.13 % des individus n’ont jamais eu

d'AVC, contre 4.87 % en ayant déjà subi un.

Ce **déséquilibre important** est fréquent dans les jeux de données médicaux. Toutefois, il peut poser problème : les modèles ont tendance à privilégier la classe majoritaire (0), au détriment de la détection des cas positifs (1).

Pour remédier à ce problème, plusieurs stratégies de rééquilibrage ont été mises en œuvre :

- Un suréchantillonnage de la classe minoritaire à l'aide de différents over-ratios,
- Une pondération des observations selon leur classes,
- Un ajustement du seuil de décision.

Ces différentes approches ont été explorées et comparées pour chaque modèle, dans le but d'améliorer leur capacité à identifier efficacement les cas d'AVC, tout en limitant les faux positifs.

2.3 Analyse des variables numériques

Afin de mieux comprendre les relations entre les différentes variables numériques de notre jeu de données, nous avons procédé à une analyse de corrélation.




Figure 2: Matrice de corrélation entre les variables numériques

Parmi les variables numériques, la corrélation la plus élevée est de 0.33, observée entre l'âge et l'indice de masse corporelle. Cette corrélation positive indique une relation modérée entre ces deux variables. Concrètement, cela suggère qu'à mesure que l'âge des patients augmente, leur IMC tend à augmenter également, bien que cette relation ne soit pas très forte.

Cela pourrait refléter certaines tendances physiologiques avec l'âge. Cependant, l'absence de corrélations fortes indique peu de redondance dans les variables explicatives, ce qui est favorable pour la majorité des algorithmes.

2.4 Analyse des variables catégorielles

L'analyse des correspondances multiples (ACM) a été utilisée pour explorer les liens entre les variables qualitatives. Cette méthode fournit une visualisation des regroupements de modalités et peut aider à identifier des **profils types de patients**. Par exemple, les résultats suggèrent que des individus fumeurs, hypertendus et ayant des antécédents de maladies cardiaques se regroupent visuellement dans

l'espace factoriel, indiquant un risque accru d'AVC. La *Figure A.3 en annexe* montre la représentation conjointe des individus et des modalités, permettant d'orienter la sélection des variables pertinentes pour la modélisation.

3 Méthodologie

3.1 Échantillonnage

Le jeu de données a été divisé en deux sous-ensembles :

- Entraînement (2/3 des données)
- Test (1/3 des données)

Les proportions de la variable cible ont été vérifiées dans chaque échantillon pour garantir leur représentativité :

Table 3: Proportions de la variable 'stroke' dans le jeu d'entraînement

Stroke	Effectif	Proportion (%)
1	172	5.05
0	3234	94.95

Table 4: Proportions de la variable 'stroke' dans le jeu de test

Stroke	Effectif	Proportion (%)
1	77	4.52
0	1627	95.48

Les proportions de la variable cible 'stroke' sont similaires dans les deux échantillons : environ 5 % des individus n'ont jamais eu d'AVC, contre 95 % ayant déjà subi un AVC, aussi bien dans le jeu d'entraînement que dans le jeu de test. L'échantillon d'entraînement est composé de 3406 individus et celui de test est composé de 1704 individus.

Cette séparation permet de former les modèles sur un ensemble, tout en évaluant leur généralisation sur un échantillon indépendant.

3.2 Prétraitement des données

Le package *tidymodels* a été utilisé pour encadrer le processus de modélisation. Des recettes spécifiques ont été créées pour adapter le prétraitement à chaque algorithme.

- Encodage des variables catégorielles : requis pour les modèles comme k-NN, SVM, LDA, QDA et boosting.
- Mise à l'échelle des variables numériques : nécessaire pour les modèles sensibles aux distances.
- Les arbres de décision (CART) et forêts aléatoires acceptent les variables catégorielles sans transformation.

3.3 Gestion du déséquilibre

Trois techniques complémentaires ont été testées :

- Suréchantillonnage (ex. : `over_ratio()`)
- Pondération des classes dans les modèles (ex. : paramètre `classwt` dans `randomForest`)
- Modification du seuil de classification pour favoriser la détection des AVC

3.4 Évaluation des modèles : Métriques utilisées

Les performances des modèles ont été comparées selon plusieurs métriques de classification :

- AUC (aire sous la courbe ROC),
- Précision,
- Rappel (Sensibilité) et,
- F1-score.

L'accent a été mis sur l'AUC et le rappel, deux indicateurs clés dans le domaine médical. L'analyse des erreurs de type I et II a également été intégrée afin d'évaluer les risques cliniques associés aux mauvaises classifications.

4 Les modèles

4.1 L'analyse discriminante linéaire (LDA)

Nous entamons la phase de modélisation avec l'Analyse Discriminante Linéaire (LDA), un modèle classique de classification. La LDA repose sur l'hypothèse de normalité des données et de matrices de covariance égales entre classes. Elle cherche à projeter les individus dans un espace où les classes sont linéairement séparables.

Pour évaluer les performances du modèle LDA dans sa version initiale, nous avons observé la matrice de confusion.

Nous avons constaté que seulement 7 cas d'AVC ont été correctement identifiés par le modèle, ce qui indique une incapacité à détecter efficacement les cas d'AVC. Ce comportement s'explique par le déséquilibre marqué entre les classes.

Pour y remédier, nous avons exploré plusieurs stratégies de suréchantillonnage :

- Un over-ratio de 1 maximise à la fois l'aire sous la courbe ROC (AUC) et le rappel, indiquant une meilleure capacité à détecter les AVC.
- Un over-ratio de 0.3, quant à lui, offre la meilleure valeur de F1-score, représentant un compromis entre précision et rappel.

Afin d'améliorer les performances de notre modèle LDA dans ce contexte déséquilibré, nous avons comparé ces trois variantes dans le tableau ci-dessous:

Table 5: Comparaison des métriques LDA selon l’over-ratio

over_ratio	AUC	precision	recall	spec	f1_score	err_glob	err_type_I	err_type_II	TP	TN
modèle de base	0.828	0.250	0.091	0.987	0.133	0.053	0.750	0.042	7	1606
0.3	0.835	0.193	0.480	0.905	0.275	0.114	0.807	0.026	37	1472
1	0.837	0.124	0.818	0.727	0.215	0.269	0.876	0.012	63	1182

Le modèle de base, bien qu’il affiche une AUC ROC acceptable (0.8279), souffre d’un rappel extrêmement faible (9.09 %). Il ne parvient quasiment pas à détecter les individus ayant subi un AVC, au profit d’une spécificité élevée (0.9871). Ce déséquilibre traduit un fort biais en faveur de la classe majoritaire, rendant ce modèle peu adapté à notre objectif prioritaire : la détection efficace des AVC.

En revanche, un over-ratio de 1 modifie profondément le comportement du modèle : le rappel atteint 82 %, traduisant une bien meilleure capacité à identifier les cas d’AVC. Toutefois, cette amélioration se fait au détriment de la précision, qui devient la plus faible parmi les modèles testés. Par ailleurs, pour une légère réduction de l’erreur de type II, l’erreur globale ainsi que l’erreur de type I sont sensiblement plus élevées.

Nous avons retenu le modèle avec un over-ratio de 0.3, qui offre un bon compromis entre détection des AVC (sensibilité) et contrôle des erreurs de classification (spécificité).

L’aire sous la courbe ROC obtenue pour ce modèle est satisfaisante (0.8352), ce qui indique une bonne capacité de discrimination entre les patients ayant ou non subi un AVC.

La *Table B.1 en annexe* présente la **matrice de confusion** associée au seuil standard de 0.5, sur les données de test. Cette analyse constitue une première étape vers l’optimisation des seuils de décision, dans l’objectif d’améliorer la détection des cas d’AVC dans un contexte médical.

Table 6: Matrice de confusion - Seuil 0.2

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	64	467	531
0 (Non AVC)	13	1160	1173
Total	77	1627	1704

Parmi les différents seuils testés, nous avons décidé de retenir un seuil de 0.2. Avec ce seuil, le modèle parvient à identifier 64 cas d’AVC, tout en limitant les faux positifs à 467. Ce compromis nous semble le plus pertinent, et ce modèle est donc conservé.

4.2 L’analyse discriminante quadratique (QDA)

Nous poursuivons notre analyse avec l’Analyse Discriminante Quadratique (QDA), un modèle de classification proche de la LDA, mais plus flexible : il autorise chaque classe à disposer de sa propre matrice de covariance. Cette particularité permet à la QDA de mieux s’adapter à des frontières de décision non linéaires, notamment lorsque les classes sont complexes à séparer dans l’espace des variables.

Afin d’assurer la cohérence de notre approche, nous avons conservé une méthodologie similaire à celle utilisée pour la LDA, tout en introduisant une réduction de dimensionnalité via l’Analyse en Composantes Principales (ACP). Cette étape, appliquée aux variables numériques, vise à éliminer le bruit et la redondance tout en conservant au moins 95 % de la variance totale.

De plus, pour réduire le déséquilibre de classes, nous avons appliqué un sur-échantillonnage avec un over-ratio de 0.3, identique à celui retenu pour le modèle LDA. Cela permet une comparabilité directe des résultats entre les deux méthodes.

Pour évaluer les performances du modèle QDA, nous avons observé la matrice de confusion associée au modèle de base au seuil de décision à 0.5 (*voir Table B.2 en annexe*).

Cette *figure B.2* révèle une meilleure détection des AVC que le modèle LDA de base, avec 46 cas correctement prédits. Le nombre de mal classés reste raisonnable, suggérant une bonne capacité de généralisation du modèle. Ces premiers résultats sont renforcés par une AUC ROC de 0.8183, indicateur d’une performance globale satisfaisante.

Nous avons ensuite exploré différents seuils de décision afin d’optimiser la balance entre faux positifs et vrais positifs (Figure B.3) :

- À un seuil de 0.1, le modèle détecte davantage de cas d’AVC, mais au prix d’un grand nombre de faux positifs. Il devient alors trop “généraliste”, prédictif même chez des individus sains (*voir Table B.4 en annexe*).
- Un seuil plus élevé diminue ces faux positifs, mais accroît le risque de faux négatifs, ce qui est inacceptable dans un contexte médical.

Ce compromis est crucial : en contexte de détection médicale, minimiser les erreurs de type II (cas d’AVC non détectés) est souvent plus important que de limiter les faux positifs, qui peuvent être rattrapés par des examens complémentaires.

Table 7: Matrice de confusion - Seuil 0.2

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	61	508	569
0 (Non AVC)	16	1119	1135
Total	77	1627	1704

Après évaluation, nous avons retenu un seuil de 0.2, qui permet d’atteindre une détection de 61 cas d’AVC, tout en gardant un niveau de faux positifs acceptable. Ce choix reflète le meilleur compromis entre rappel, précision et coût d’une mauvaise classification.

4.3 Modèle des k plus proches voisins (knn)

Le troisième modèle testé repose sur l’algorithme des k plus proches voisins (k-NN), une méthode non paramétrique qui attribue à un individu la classe majoritaire parmi ses k voisins les plus proches. Ne

reposant sur aucune hypothèse forte, ce modèle offre une alternative intéressante dans notre démarche comparative.

Comme pour les modèles précédents, nous avons utilisé un over-ratio de 0.3 afin de corriger le déséquilibre entre les classes. Sans suréchantillonnage, le modèle s’est révélé très biaisé, classant systématiquement les individus comme positifs, ce qui confirme l’importance d’un rééquilibrage préalable des données.

Nous avons ensuite testé différentes valeurs de l’hyperparamètre k afin d’optimiser les performances du modèle.




Figure 3: Visualisation du paramètre k selon les métriques - KNN

Plusieurs valeurs de l’hyperparamètre k ont été testées. Si des valeurs faibles (par ex. $k = 5$) offrent une faible AUC (autour de 0.6), des valeurs plus élevées permettent d’améliorer à la fois le rappel et le F1-score. Toutefois, au-delà d’un certain seuil, les gains en performance deviennent marginaux, tandis que la spécificité diminue, traduisant une augmentation des faux positifs.

Le choix de 20 représente donc un compromis optimal, conciliant stabilité, précision et sensibilité.

La *Table B.5 en annexe* illustre la matrice de confusion avec un over-ratio et un seuil de décision de 0.5. Avec ce paramètre, le modèle atteint un rappel de 20.78 %, détectant 16 cas d’AVC. Toutefois, la proportion de faux négatifs reste élevée, ce qui limite son efficacité pour une détection précoce. En parallèle, l’erreur globale est faible (13.2 %), principalement portée par les 1463 vrais négatifs, témoignant de la bonne capacité du modèle à identifier les non-AVC. L’erreur de type I reste en revanche trop élevée dans un contexte médical, où les faux négatifs sont les plus coûteux.

Malgré une AUC satisfaisante (0.6943), le modèle reste trop conservateur. Une optimisation du seuil de décision a été envisagée pour améliorer la sensibilité.

Table 8: Matrice de confusion - Seuil 0.2

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	41	392	433
0 (Non AVC)	36	1235	1271
Total	77	1627	1704

Le seuil retenu, à 0.2, permet de détecter 41 cas d'AVC, avec une erreur globale de 25.12 %. Ce compromis améliore le rappel, au prix d'un nombre plus élevé de faux positifs, mais reste plus adapté à notre objectif prioritaire de détection des AVC.

4.4 SVM Linéaire (Support Vector Machine)

Le SVM linéaire est un modèle efficace pour les données linéairement séparables, fondé sur le principe de maximisation de la marge entre les classes. Il constitue notre quatrième approche, poursuivant le même objectif : détecter efficacement les AVC tout en maintenant un bon équilibre entre rappel, précision et erreurs.

Comme précédemment, un over-ratio de 0.3 a été appliqué pour atténuer le déséquilibre des classes. Sans ce rééquilibrage, le modèle présentait de faibles performances, notamment en rappel.




Figure 4: Visualisation du paramètre cost selon les métriques - SVM linéaire

L'optimisation du paramètre de régularisation **cost** a mis en évidence deux valeurs intéressantes :

- 1.26 maximisant le rappel,
- 0.184 maximisant l'AUC.

Les matrices de confusion associées à ces deux configurations se sont révélées proches, traduisant une bonne stabilité du modèle. Nous avons retenu la valeur 0.184, légèrement plus souple, qui favorise une meilleure généralisation sans trop sacrifier la détection.

Avec ce paramétrage, le modèle affiche un rappel de 37.66 %, soit 29 cas d'AVC détectés, tout en conservant une spécificité élevée et un faible taux de faux positifs (1496 vrais négatifs). L'erreur globale reste faible (10.5 %), et l'AUC atteint 0.8216, témoignant d'un bon équilibre entre sensibilité et spécificité.

Table 9: Matrice de confusion - Seuil 0.2

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	58	439	497
0 (Non AVC)	19	1188	1207
Total	77	1627	1704

Deux seuils ont été comparés (*voir Figure B.6 en annexe*):

- Le seuil à 0.3 offre une erreur globale contenue, une erreur de type I modérée, et permet de détecter 53 cas d'AVC. Il représente un compromis équilibré.
- Le seuil à 0.2, plus permissif, améliore le rappel (58 cas d'AVC détectés), au prix d'une hausse significative des faux positifs. L'erreur globale atteint 26.88%.

Dans un contexte médical, il est préférable de réduire l'erreur de type II, même au prix de quelques fausses alertes. Le second seuil, plus sensible, est donc retenu.

Le SVM linéaire, avec un coût optimisé à 0.184 et un seuil à 0.2, se montre robuste, équilibré et performant (0.8216 en AUC). Il constitue une solution pertinente pour la détection précoce des AVC.

4.5 SVM noyau radial

Le SVM radial permet de modéliser des frontières de décision complexes en projetant les données dans un espace de plus grande dimension. Il s'agit ici d'une extension non linéaire du SVM linéaire, mieux adaptée aux structures non linéaires.

Contrairement aux modèles précédents, un over-ratio de 0.3 s'est avéré insuffisant. Nous avons donc retenu un over-ratio plus élevé, 0.5, afin de mieux représenter la classe minoritaire (AVC) et d'améliorer les performances.

L'optimisation a porté sur deux hyperparamètres :

- C (pénalité des erreurs de classification),
- sigma (définit l'influence locale des observations).




Figure 5: Visualisation du paramètre cost et sigma selon les métriques - SVM radial

Nous avons comparé deux valeurs de C :

- 0.1 (meilleure AUC),
- 1 (meilleur rappel),

avec un sigma fixé à 0.01, indiquant un modèle peu sensible au bruit.

Un C élevé (1) réduit les erreurs mais rend le modèle plus rigide. Nous avons retenu cette valeur pour **maximiser le rappel**, essentiel dans un contexte médical.

La Table B.7 en annexe illustre la matrice de confusion avec ces paramètres. le modèle atteint une AUC de 0.8281, une erreur globale modérée (17.55 %), et détecte 44 cas d'AVC. L'erreur de type II reste notable (42.86 %), soulignant qu'une partie des AVC n'est pas détectée malgré des performances globalement satisfaisantes.

Ce graphique nous permettra d'analyser l'évolution des différentes métriques en fonction du seuil de décision, afin d'identifier celui qui optimise les performances globales du modèle.




Figure 6: Évolution des métriques selon le seuil - SVM radial

Un ajustement du seuil de décision permet d'affiner le compromis entre rappel et spécificité. L'analyse graphique montre un seuil optimal autour de 0.25. Comparé à un seuil à 0.3, un seuil plus bas (0.2) améliore significativement le rappel, au détriment de la spécificité, qui chute en raison d'un plus grand nombre de faux positifs.

Malgré une légère baisse de la précision, le F1-score reste stable. Étant donné notre priorité de détection des AVC, nous retenons le seuil à 0.2.

Table 10: Matrice de confusion - Seuil 0.2

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	67	542	609
0 (Non AVC)	10	1085	1095
Total	77	1627	1704

Avec ce seuil (0.2), le modèle détecte 67 cas, soit 89.61 % des cas positifs, et maintient une faible erreur de type II (12.99%). En contrepartie, l'erreur de type I augmente (33.31 %), ce qui reste acceptable dans

notre cadre.

Le SVM radial, avec un seuil ajusté à 0.2 et des paramètres optimisés (1, 0.01), offre un excellent compromis entre rappel élevé et performance globale (32.39 % d'erreur globale). Il s'impose comme une solution pertinente pour la détection précoce des AVC.

4.6 Arbres de décision CART

Les arbres de décision, ou modèles CART (Classification and Regression Trees), segmentent l'espace des données en sous-groupes homogènes à l'aide de règles simples basées sur les variables explicatives. Leur popularité tient à leur simplicité, capacité à modéliser des interactions complexes, et surtout à leur interprétabilité.

Nous avons d'abord utilisé le package tidymodels pour entraîner un modèle CART avec recherche d'hyperparamètres. Cependant, ce dernier privilégiait systématiquement la classe majoritaire, réduisant fortement la capacité de détection des AVC.

Nous avons donc opté pour le package rpart, qui offre un meilleur contrôle sur la profondeur de l'arbre.

Afin de limiter les biais, les classes ont été pondérées à parts égales (0.5). L'arbre a d'abord été construit sans restriction de profondeur, puis élagué pour éviter le surapprentissage.




Figure 7: Erreur de validation croisée selon le nombre de splits

L'analyse de l'évolution de l'erreur de validation croisée nous a conduit à retenir un arbre avec 5 splits correspondant à un coût de complexité (cp) de 0.0111. Ce point représente un équilibre optimal entre complexité et généralisation.

Nous présentons ci-dessous l'arbre de décision obtenu après élagage, illustrant les règles de segmentation apprises par le modèle à partir des variables explicatives :




Figure 8: Représentation de l'arbre de décision

L'arbre élagué met en évidence les règles de segmentation et les variables les plus influentes. La *figure B.8* présente l'importance des variables (*voir Figure B.8 en annexe*). La représentation de l'arbre de décision nous montre que l'**âge** ressort comme le facteur dominant.

Avec un seuil classique de 0.5, le modèle détecte 62 cas d'AVC, soit un rappel de 80.52 %, ce qui est satisfaisant dans un contexte médical. La précision reste faible (11.68 %), ce qui indique un taux de faux positifs élevé, mais la spécificité est correcte (71.17 %). L'AUC du modèle est également satisfaisante (0.8172), montrant une bonne capacité de discrimination.

Nous avons ensuite étudié l'impact du seuil de décision sur les performances, en comparant les résultats obtenus avec un seuil ajusté à 0.2 versus 0.5.




Figure 9: Matrices de confusion CART - Seuils

- À 0.2, le modèle devient plus sensible, détectant davantage de cas d'AVC (68 au lieu de 62).
- Cette hausse du rappel se traduit par une baisse de la précision et de la spécificité, ainsi qu'une augmentation de l'erreur globale (34.92 %).
- Le taux de faux positifs (erreur de type I) augmente, ce qui reste acceptable dans une logique de surveillance médicale préventive.

Ce modèle CART, bien que simple, parvient à détecter efficacement les AVC, en particulier avec un seuil abaissé à 0.2, qui maximise le rappel. Sa lisibilité et sa capacité d'interprétation en font un outil pertinent

dans une démarche explicative, même si sa précision reste perfectible.

4.7 Random forest

Nous avons ensuite exploré des méthodes d'ensemble, en particulier la forêt aléatoire et le bagging, qui reposent sur la combinaison de plusieurs arbres de décision pour améliorer la robustesse du modèle. Ces techniques permettent de réduire la variance, limiter le surapprentissage, et mieux généraliser.

Le prétraitement des données a été effectué à l'aide du package `recipes`, avec une imputation KNN pour les valeurs manquantes. Ensuite, deux modèles ont été entraînés :

- Une forêt aléatoire standard, avec l'algorithme `randomForest`, utilisant le critère de Gini et un équilibrage des classes via les poids `classwt = c(0.5, 0.5)`.
- Un modèle de bagging, qui correspond à une forêt aléatoire sans sélection aléatoire de variables (`mtry = 10`, qui correspond au nombre total de variables explicatives), ce qui maximise la stabilité au détriment d'une possible perte de diversité entre les arbres.

Une grille d'hyperparamètres a été définie pour optimiser les valeurs de `mtry`, `min_n`, ainsi que le nombre d'arbres. L'intervalle retenu pour le nombre d'arbres varie de 350 à 500, tandis que le nombre de variables utilisées à chaque division (`mtry`) est compris entre 2 et 8.




Figure 10: Visualisation des hyper-paramètres - Random forest

L'optimisation des hyperparamètres a été réalisée en maximisant le rappel, métrique essentielle dans un contexte médical où l'objectif principal est de minimiser les faux négatifs (cas d'AVC non détectés). Le meilleur ensemble de paramètres retenu correspond à 387 arbres, 6 variables aléatoirement sélectionnées à chaque division et un nombre minimal d'observations par nœud terminal de 6.

Ce paramétrage reflète un compromis pertinent : un nombre élevé d'arbres assure une meilleure stabilité du modèle, un `mtry` relativement large permet de capter davantage d'interactions entre variables à chaque split, tandis qu'un `min_n` modéré évite de trop fragmenter les feuilles, ce qui limite le surapprentissage tout en conservant une certaine sensibilité au signal minoritaire. Cette combinaison vise donc à renforcer la capacité du modèle à identifier les cas rares d'AVC, tout en maintenant une généralisation correcte. (Voir Figure B.9 en annexe pour l'importance des variables)

Avec un seuil de décision à 0.5, le modèle Random Forest affiche une spécificité très élevée (99.88%),

traduisant une excellente capacité à détecter les non-AVC. L'AUC globale s'élève à 0.8157, indiquant une bonne capacité de discrimination entre les classes. Cependant, les performances sont fortement déséquilibrées : le rappel est extrêmement faible (1.3%), avec seulement 1 cas d'AVC détectés sur 77, ce qui montre que le modèle échoue à identifier correctement les cas positifs. Le F1-score est quasi nul (`r_f1_score`) et la précision modérée (33.33%), en raison du très faible nombre de prédictions positives.

Le taux d'erreur global, bien que relativement bas (4.58 %), masque cet important déséquilibre. Ce seuil de classification privilégie fortement les prédictions négatives, ce qui est problématique en contexte médical, où la non-détection d'un AVC peut avoir de graves conséquences. Ce comportement reflète un biais fort en faveur de la classe majoritaire, typique des modèles entraînés sur des données déséquilibrées. (Voir Table B.10 en annexe)




Figure 11: Matrice de confusion Random Forest - Seuil 0.1

En abaissant le seuil à 0.1, le modèle devient plus sensible aux cas d'AVC : le rappel augmente fortement, avec 45 AVC correctement détectés. Cela s'accompagne d'une chute de la spécificité, et d'une hausse notable des faux positifs (295). Le F1-score progresse, reflétant un meilleur équilibre entre précision et rappel, même si la précision reste faible, en raison du grand nombre d'alertes inutiles. Le taux d'erreur global augmente à 19.19%, un compromis acceptable dans un contexte médical, où la détection des cas graves (AVC) prime sur le confort.

Nous retenons ce modèle Random Forest avec un seuil ajusté à 0.1, car il permet une meilleure détection des AVC, en dépit d'une précision plus faible, ce qui est préférable dans un contexte médical où l'objectif principal est de minimiser les faux négatifs.

4.8 Boosting

Afin d'améliorer les performances de détection, nous avons exploré l'approche du boosting, en particulier à travers l'algorithme XGBoost, réputé pour sa capacité à modéliser des relations complexes et à corriger les erreurs des modèles précédents. Une recette de prétraitement a été appliquée, incluant l'imputation KNN, la normalisation des variables numériques, la création de variables fictives pour les qualitatives, ainsi qu'un suréchantillonnage (`over_ratio` de 0,3) afin de limiter les effets du déséquilibre de classes et garder une cohérence avec les modèles vu précédemment.

L'optimisation des hyperparamètres du modèle Boosting a été réalisée en deux étapes successives. Une première recherche par grille large a permis d'explorer différentes valeurs de `trees`, `tree_depth` et `learn_rate`

(cf. Figure B.11 en annexe). À partir des combinaisons prometteuses, une deuxième grille affinée a été utilisée pour affiner la recherche sur l'hyperparamètre *learn_rate*, en fixant les valeurs optimales identifiées pour *trees* et *tree_depth*.




Figure 12: Affinage de l'hyperparamètre 'learn_rate' pour le modèle Boosting

L'optimisation des hyperparamètres a porté sur trois dimensions clés : le nombre d'arbres (*trees*), la profondeur maximale des arbres (*tree_depth*) et le taux d'apprentissage (*learn_rate*). L'évaluation a été réalisée à l'aide d'une validation croisée stratifiée, en privilégiant la maximisation du rappel, métrique essentielle dans un contexte médical.

L'optimisation a retenu la combinaison suivante : 450 arbres, une profondeur de 1, et un taux d'apprentissage de 0.015, ce qui traduit une stratégie conservatrice favorisant la stabilité et la régularisation, avec des arbres peu profonds et un faible pas d'apprentissage, adaptés à un objectif de généralisation et de détection de la classe minoritaire (AVC).

Avec ces paramètres, le modèle atteint un rappel de 28.57%, détectant 22 cas d'AVC. L'erreur globale reste faible (8.63%), principalement grâce aux 1535 vrais négatifs. Toutefois, la proportion de faux positifs est élevée (erreur de type I : 80.7 %), ce qui peut limiter la fiabilité du modèle. Malgré une AUC satisfaisante (0.8432), le modèle reste perfectible pour une détection précoce, justifiant l'exploration de seuils ajustés pour améliorer la sensibilité. (voir Table B.12 en annexe)




Figure 13: Matrice de Confusion Boosting - Seuil 0.2

Afin d'améliorer la sensibilité du modèle, plusieurs seuils de décision ont été testés. Le seuil de 0.2 a été retenu car il offre un bon compromis entre rappel et spécificité. Ce seuil permet d'augmenter fortement la

détection des cas d'AVC par rapport au seuil standard (0.5), tout en limitant la hausse des faux positifs par rapport à des seuils plus bas. En effet, le modèle Boosting permet de prédire 67 AVC et `rFP_Boost`. Le F1-score progresse également, signalant un meilleur équilibre entre précision et rappel.

Ce choix renforce la capacité du modèle à repérer les AVC, ce qui est essentiel dans un contexte médical, tout en maîtrisant le coût en fausses alertes.

5 Comparaison des modèles

Après avoir entraîné et évalué nos modèles de classification, nous avons comparé leurs performances à l'aide de plusieurs indicateurs clés : l'AUC, la précision, le rappel, le F1-score, le taux d'erreur global, ainsi que les erreurs de type I et II afin de choisir quel modèle de classification prédit un maximum d'individu souffrant d'AVC.

Pour cela, nous allons pouvoir présenter dans un tableau chacun de modèle ainsi que les métriques associées :

Table 11: Comparaison des modèles triés par l'AUC

modèles	AUC	precision	recall	spec	f1_score	err_glob	err_type_I	err_type_II	TP	TN
Boosting	0.843	0.091	0.922	0.564	0.166	0.339	0.348	0.130	67	1060
LDA	0.837	0.121	0.831	0.713	0.211	0.282	0.287	0.169	64	1160
SVM radial	0.828	0.110	0.870	0.667	0.195	0.324	0.333	0.130	67	1085
SVM linéaire	0.822	0.117	0.753	0.730	0.202	0.269	0.270	0.247	58	1188
QDA	0.818	0.107	0.792	0.688	0.189	0.308	0.312	0.208	61	1119
Modèle CART	0.817	0.104	0.883	0.640	0.186	0.349	0.360	0.117	68	1041
Random Forest	0.815	0.132	0.584	0.819	0.216	0.192	0.181	0.416	45	1332
KNN	0.694	0.095	0.532	0.759	0.161	0.251	0.241	0.468	41	1235

5.1 Analyse des performances

Le **modèle Boosting** ressort comme le modèle le plus performant sur plusieurs aspects :

- Il atteint le **meilleur score AUC** (0.8432), ce qui indique une excellente capacité à distinguer les classes positives et négatives.
- Il présente également le **meilleur rappel** (0.9221), ce qui signifie qu'il identifie presque tous les cas positifs (67).
- Son **taux d'erreur de type II** est dans les 3 plus **faibles** (0.1299), ce qui est particulièrement important si l'objectif est de minimiser les faux négatifs.

Ces caractéristiques font du modèle Boosting un choix idéal dans un contexte où il est prioritaire de ne pas manquer les cas positifs, comme dans un système de détection de maladies, de fraudes ou de risques.

Cependant, ce modèle présente également quelques limites :

- Sa précision est relativement faible (0.091), ce qui signifie qu'il génère un nombre important de faux positifs.

- Son F1-score (0.1657), qui reflète le compromis entre précision et rappel, est l'un des plus faibles.

À titre de comparaison, le **modèle Random Forest** affiche :

- Le **meilleur F1-score** (0.2158), ce qui indique un meilleur équilibre entre rappel et précision.
- Le **plus faible taux d'erreur global** (0.1919).
- Une **spécificité élevée** (0.8187), ce qui réduit les faux positifs.

En revanche, **son rappel est le plus bas** (0.5844), ce qui signifie qu'il rate davantage de cas positifs que le Boosting.

5.2 Conclusion

En définitive, le choix du modèle dépend de nos priorités :

- Si l'objectif est de **maximiser la détection des cas positifs** (minimiser les faux négatifs), alors le modèle Boosting est le plus approprié, malgré sa précision plus faible.
- Si l'on souhaite un **modèle plus équilibré**, avec moins de faux positifs et une meilleure précision, le Random Forest constitue une alternative intéressante.

Dans notre cas, considérant que l'identification complète des cas positifs est prioritaire, nous **retenons le modèle Boosting** comme modèle final.

6 Annexe

6.1 Annexe A - Introduction

- A.1 - Visualisation des données manquantes dans le jeu de données initial




Figure 14: Visualisation des données manquantes dans le jeu de données initial

Description : Ce graphique met en évidence la distribution des valeurs manquantes parmi les variables du jeu de données. Les zones foncées représentent les valeurs manquantes, facilitant l'identification des variables les plus concernées.

- A.2 - Histogrammes superposés de la variable 'bmi' avant et après imputation par k-NN ($k = 5$)




Figure 15: Histogrammes superposés de la variable 'bmi' avant et après imputation par k-NN ($k = 5$)

Description : L'histogramme compare la distribution de la variable bmi avant (bleu) et après imputation

par k-NN avec $k = 5$ (orange). L'imputation respecte la structure globale des données, ce qui limite le risque d'introduire un biais.

- *A.3 – Représentation factorielle des individus et des modalités selon l'analyse des correspondances multiples (ACM)*




Figure 16: Représentation factorielle des individus et des modalités selon l'analyse des correspondances multiples (ACM)

Description : Le nuage d'individus coloré selon la variable stroke permet d'observer des regroupements potentiels. Les ellipses convexes aident à identifier visuellement les zones de concentration. Le nuage des modalités met en évidence les associations entre modalités comme fumeur, hypertendu ou antécédents cardiaques et le risque d'AVC.

6.2 Annexe B - Les modèles

- *Annexe B.1 - Matrice de confusion du modèle LDA avec over-ratio 0.3 (seuil de décision = 0.5)*

Table 12: Matrice de confusion du modèle LDA avec over-ratio 0.3 (seuil de décision = 0.5)

Prédiction	Réalité		Total
	1 (AVC)	0 (Pas d'AVC)	
1 (AVC)	22	92	114
0 (Pas d'AVC)	55	1535	1590
Total	77	1627	1704

Annexe B.2 - Matrice de confusion du modèle QDA avec over-ratio 0.3 (seuil de décision = 0.5)

Table 13: Matrice de confusion du modèle QDA avec over-ratio 0.3 (seuil de décision = 0.5)

Prédiction	Réalité		Total
	1 (AVC)	0 (non AVC)	
1 (AVC)	46	312	358
0 (non AVC)	31	1315	1346
Total	77	1627	1704

Annexe B.3 - Évolution des métriques selon le seuil - QDA




Figure 17: Évolution des métriques selon le seuil - QDA

Annexe B.4 - Matrice de confusion du modèle QDA avec over-ratio 0.3 (seuil de décision = 0.1)

Table 14: Matrice de confusion du modèle QDA avec over-ratio 0.3 (seuil de décision = 0.1)

Prédiction	Réalité		Total
	1 (AVC)	0 (non AVC)	
1 (AVC)	69	609	678
0 (non AVC)	8	1018	1026
Total	77	1627	1704

Annexe B.5 - Matrice de confusion du modèle KNN avec over-ratio 0.3 (seuil de décision = 0.5)

Table 15: Matrice de confusion du modèle KNN avec over-ratio 0.3 (seuil de décision = 0.5)

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	

1 (AVC)	16	164	180
0 (Non AVC)	61	1463	1524
Total	77	1627	1704

Annexe B.6 - Comparaison Matrices de confusion du modèle SVM linéaire avec over-ratio 0.3 (seuil de décision = 0.1,0.2,0.5)




Figure 18: Comparaison Matrices de confusion du modèle SVM linéaire avec over-ratio 0.3 (seuil de décision = 0.1,0.2,0.5)

Annexe B.7 - Matrice de confusion du modèle KNN avec over-ratio 0.3 (seuil de décision = 0.5)

Table 16: Matrice de confusion du modèle SVM radial avec over-ratio 0.3 (seuil de décision = 0.5)

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	44	266	310
0 (Non AVC)	33	1361	1394
Total	77	1627	1704

Annexe B.8 - Importance des variables la construction du modèle CART




Figure 19: Importance des variables dans le modèle CART

Description : La variable dominante est l'**âge** suivie par le **statut matrimonial**, le type d'emploi, le niveau de glucose, et l'IMC. À l'inverse, les antécédents de **maladies cardiaques** ont un poids très limité. Cette hiérarchisation des variables est cohérente avec les connaissances médicales et illustre bien l'interprétabilité du modèle.

Annexe B.9 - Importance des variables dans le modèle Random forest




Figure 20: Importance des variables dans le modèle Random Forest

Description : Les trois variables les plus importantes pour prédire les AVC sont : le taux moyen de glucose, l'IMC et l'âge. Cela montre que les facteurs métaboliques et l'âge jouent un rôle clé dans la d'identification des risques d'AVC. Ces résultats soulignent l'importance d'une surveillance ciblée sur ces variables pour la prévention des AVC.

Annexe B.10 - Matrice de confusion du modèle Random Forest (seuil de décision = 0.5)

Table 17: Matrice de confusion du modèle Random Forest (seuil de décision = 0.5)

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	1	2	3
0 (Non AVC)	76	1625	1701
Total	77	1627	1704

Annexe B.11 - Résultats de la recherche par grille – Boosting




Figure 21: Résultats de la recherche par grille – Boosting

Description : Nous observons que les meilleures performances sont obtenues pour un *learning rate* compris entre 0.01 et 0.05, en combinaison avec au moins 400 arbres. Ces configurations semblent offrir un bon compromis entre complexité du modèle et capacité de généralisation. Ces observations ont guidé l’affinage des hyperparamètres dans notre seconde étape.

Annexe B.12 - Matrice de confusion du modèle Boosting (seuil de décision = 0.5)

Table 18: Matrice de confusion du modèle Boosting (seuil de décision = 0.5)

Prédiction	Réalité		Total
	1 (AVC)	0 (Non AVC)	
1 (AVC)	22	92	114
0 (Non AVC)	55	1535	1590
Total	77	1627	1704